



YASSIR CHERGUI

Ingénierie IA | LLM, RAG & systèmes multi-agents

Master d'Excellence en Science des Données et Intelligence Artificielle

Meknès, Maroc | +212 693 534 651 | cherguiyassir1@gmail.com

chergui-yassir.vercel.app | linkedin.com/in/yassir-chergui | github.com/YassirCher

Disponible immédiatement pour un poste en ingénierie IA/ML ou Data Science, ou un stage pré-embauche

PROFIL PROFESSIONNEL

Titulaire d'un Master d'Excellence en Science des Données et Intelligence Artificielle, spécialisé en ingénierie IA : automatisation, LLM, RAG, systèmes multi-agents et applications de bout en bout. Compétences en Data Science, ML/DL, MLOps, vision et séries temporelles. Créateur de ThinkGraph AI, plateforme multimodale intégrant fine-tuning, recherche hybride, graphes de connaissances, backend, tests et cloud.

PROJET DE FIN D'ÉTUDES (PFE)

ThinkGraph AI - Plateforme de recherche multi-agents et multimodale

Ingénierie IA, Data Science et Deep Learning

01 avril 2026 - 08 septembre 2026

Technologies : Python, PyTorch, Hugging Face, QLoRA, LangGraph, LightRAG, FastAPI, Next.js, Neo4j, Qdrant, PostgreSQL, Redis, Docker, Azure

- Développé une plateforme transformant les textes, figures, tableaux, formules et références d'articles scientifiques au format PDF en connaissances multimodales interrogeables.
- Orchestré des workflows multi-agents pour le raffinement des requêtes, l'analyse documentaire, la mémoire graphe, la recherche hybride (sémantique, graphe et mots-clés), la génération et validation de réponses, les citations, quiz, rapports et présentations avec LightRAG, Neo4j, Qdrant et BGE-M3.
- Géré le cycle Data Science/ML pour la réponse aux questions scientifiques : préparation des données, fine-tuning, comparaison et évaluation de 13 LLM open source avec QLoRA sur QASPER ; Phi-4-mini a atteint le meilleur BERTScore F1 de 79,86% sur 256 exemples contrôlés.
- Développé et testé l'application FastAPI/Next.js avec authentification et rôles ; conteneurisé les services et automatisé le déploiement frontend sur Azure avec GitHub Actions.

Code source : dépôt GitHub privé - accès sur demande | [scientific-qa-llm-finetuning](https://github.com/scientific-qa-llm-finetuning)

COMPÉTENCES TECHNIQUES

Programmation et développement applicatif : Python, SQL, Java, TypeScript, FastAPI, Django, Spring Boot, API REST, React, Next.js, Angular

Data Science et Machine Learning : Préparation des données, feature engineering, entraînement, évaluation, séries temporelles, Scikit-learn, Pandas, NumPy, SHAP

Deep Learning et Computer Vision : PyTorch, TensorFlow, Hugging Face Transformers, YOLOv8, VideoMAE, OpenCV, Grad-CAM

LLM, RAG et IA agentique : Retrieval-Augmented Generation (RAG), LoRA, QLoRA, PEFT, LangGraph, LangChain, LightRAG, GraphRAG, embeddings, recherche hybride et vectorielle, systèmes multi-agents, prompt engineering, évaluation de LLM, Model Context Protocol (MCP)

Données, graphes et recherche : PostgreSQL, Neo4j, Qdrant, ChromaDB, Redis, MinIO

MLOps et Cloud : MLflow, Docker, Azure, GitHub Actions, CI/CD, monitoring des modèles, détection de dérive, Prometheus, Grafana, Git, Linux

SOFT SKILLS

Autonomie | Orientation résultats | Patience et persévérance | Esprit analytique | Résolution de problèmes

PROJETS SÉLECTIONNÉS

EcoForecaster - Prévision énergétique et MLOps

Technologies : Python, Scikit-learn, FastAPI, React, MLflow, SHAP, Docker, Azure

- Développé une plateforme d'analyse énergétique pour estimer la consommation actuelle et prévoir à 1 heure et 24 heures, avec services FastAPI/React conteneurisés et déploiement Azure automatisé par GitHub Actions.
- Conçu un système multi-agents MLOps : quatre agents spécialisés calculent les métriques de dérive, performance, importance des variables et santé du système ; un orchestrateur LLM les synthétise avec le contexte Graph RAG.
- Créé des workflows chronologiques d'entraînement, validation et test avec suivi d'expériences, explicabilité, détection d'anomalies et de dérive.

Dépôt : [EcoForecaster](#)

Computer Vision for Safety - Détection d'armes et de violence

Technologies : Python, PyTorch, YOLOv8, VideoMAE, OpenCV, FastAPI, Django, React

- Comparé quatre approches spatio-temporelles de deep learning pour détecter la violence et entraîné un détecteur d'armes multi-classes sur 10 887 images annotées réparties en 9 classes, atteignant un mAP@50-95 de 0,9612.
- Développé deux applications full-stack pour l'inférence sur images et vidéos, la visualisation des confiances, la gestion des utilisateurs et la génération automatique de rapports.

Dépôts : [Weapon Detection](#) | [Video Violence Detection](#)

Smart Job Matcher - Plateforme de recrutement basée sur les graphes

Technologies : Java, Spring Boot, Angular, Neo4j, recherche vectorielle, API REST

- Conçu un moteur de matching IA avec embeddings, recherche vectorielle et graphe Neo4j ; structuré les CV et profils GitHub en compétences, projets et exigences de postes pour fournir similarité sémantique, recommandations explicables et analyse des écarts au-delà des mots-clés.
- Intégré le moteur à une application Spring Boot/Angular via API REST, avec gouvernance, suivi de dérive des modèles et tests backend automatisés.

Dépôt : [Smart Job Matcher](#)

FORMATION

Université Moulay Ismail - Faculté des Sciences de Meknès 2024-2026

Master d'Excellence en Science des Données et Intelligence Artificielle

Diplôme obtenu en 2026 | Mention : Très Bien

Université Moulay Ismail - Faculté des Sciences de Meknès 2024

Licence en Sciences Mathématiques et Informatique (SMI) | Mention : Assez Bien

CERTIFICATIONS

- AWS Generative AI Applications - AWS et Coursera
- IBM Machine Learning Professional Certificate - IBM et Coursera
- Oracle Cloud Infrastructure AI Foundations Associate - Oracle University
- Intermediate Machine Learning - Kaggle

LANGUES

Arabe : langue maternelle | Français : maîtrise professionnelle | Anglais : maîtrise professionnelle